



Aprendizaje automático II
Maestría en Inteligencia Artificial
3er trimestre / 2025

Federico Albanese

Objetivos de aprendizaje: El propósito de esta materia es que los estudiantes consoliden conocimientos de Inteligencia Artificial en el marco del Deep Learning, comprendiendo en profundidad cómo funcionan, cómo se entrenan y cómo se aplican distintas arquitecturas modernas. Al finalizar, el estudiante deberá ser capaz de leer y analizar críticamente papers especializados, seleccionar técnicas adecuadas para problemas reales, y transferir el contenido teórico a casos de uso con impacto, justificando decisiones de modelado, entrenamiento y evaluación con criterios técnicos y métricas pertinentes.

Contenidos: Se abordará el aprendizaje profundo incluyendo redes neuronales profundas y sus fundamentos de optimización y regularización, redes para imágenes, redes para texto y Transformers, redes para series de tiempo, redes para grafos, aproximaciones bayesianas y nociones de causalidad para manejar incertidumbre, técnicas para sistemas de recomendación. En todos los casos se enfatizará cómo funcionan, cómo se entrenan y cómo se aplican en escenarios reales.

Modalidad de trabajo: La cursada consta de encuentros con una primera parte teórica donde se explicarán los conceptos de redes neuronales profundas y una segunda parte práctica en formato taller. Adicionalmente, se reservará tiempo de desarrollo y consultas para un trabajo práctico global que se extiende a lo largo de toda la cursada.

Mecanismo de evaluación: La evaluación combinará la lectura crítica de papers y un trabajo práctico aplicado. Los estudiantes deberán seleccionar tres papers vinculados a los contenidos de la materia y realizar una defensa breve de uno de ellos durante la novena clase. Además, desarrollarán un trabajo práctico grupal (de dos o tres integrantes). El mismo tiene una presentación inicial de avances en la sexta clase y una entrega final en la undécima clase. La entrega incluirá un informe con título, abstract, introducción, trabajos relacionados, métodos y datos, resultados y conclusiones, además de código comentado y una presentación oral acotada con espacio para preguntas. La calificación final está dada por la defensa del paper (20%), la presentación inicial del TP (30%) y la presentación final (50%).

Plagio y deshonestidad intelectual

La Universidad de San Andrés exige un estricto apego a los cánones de honestidad intelectual. La existencia de plagio constituye un grave deshonor, impropio de la vida universitaria. Su configuración no sólo se produce con la existencia de copia literal en los exámenes presenciales, sino toda vez que se advierta un aprovechamiento abusivo del esfuerzo intelectual ajeno. El [Código de Ética](#) considera conducta punible la apropiación de la labor intelectual ajena, por lo que se recomienda apegarse a los formatos académicos generalmente aceptados (MLA, APA, Chicago, etc.) para las citas y referencias bibliográficas (incluyendo los formatos *on-line*). En caso de duda recomendamos consultar el sitio: <http://www.udesa.edu.ar/Unidades-Academicas/departamentos-y-escuelas/Humanidades/Prevencion-del-plagio/Que-es-el-plagio>. La violación de estas normas dará lugar a sanciones académicas y disciplinarias que van desde el apercibimiento hasta la expulsión de la Universidad.

PROGRAMA

Relativo a todas las clases sugerimos la siguiente bibliografía:

- “Deep Learning” Ian goodfellow, yoshua bengio, aaron courville. The reference book for deep learning models, 2016, vol. 1.
- “Pattern recognition and Machine Learning”, C. Bishop, SPRINGER, Edición 2006.
- Pytorch: Ansel, J., Yang, E., He, H., Gimeshein, N., Jain, A., Voznesensky, M., ... & Chintala, S. (2024, April). Pytorch 2: Faster machine learning through dynamic python bytecode transformation and graph compilation. In Proceedings of the 29th ACM International Conference on Architectural Support for Programming Languages and Operating Systems, Volume 2 (pp. 929-947).

Unidades

- Unidad 1:
 - Introducción al aprendizaje automático clásico
 - Perceptrón simple
 - Introducción a Redes Neuronales
 - Funciones de activación
 - Regularización
- Unidad 2:
 - Embeddings
 - Word2Vec
 - Autoencoders
 - Variational Autoencoders
 - Manifolds y Autoencoders
- Unidad 3:
 - Redes Neuronales Convolucionales
 - Max Pooling
 - Semantic Segmentation
 - YOLO
 - Modelos de Difusión
 - Modelos multimodales
- Unidad 4:

- Graph Neural Networks
 - Invarianzas en los datos
 - Graph Attention Networks
 - Message-passing Neural Networks
 - Adversarial Graph Learning
- Unidad 5:
 - Datos secuenciales
 - Redes recurrentes
 - LSTMs
 - Atención
 - Transformers
 - Evaluación de transformers
- Unidad 6:
 - Large Language Models
 - Aplicaciones de LLMs
 - RAGs
 - Agentes y MCP
- Unidad 7:
 - Incertezas en redes neuronales
 - Dropout en inferencia
 - Redes Neuronales Bayesianas
 - Causalidad e Impacto causal
- Unidad 8:
 - Sistemas de recomendación
 - Embeddings de usuarios y productos
 - Two-tower neural networks
 - Expanding audiences